Wave Forecaster: o que já foi portado para a GPU

Relatório para o Prof. Pedro Cruz (GTA, DEL/Poli/UFRJ), em português técnico controlado

Matheus Hoffmann, Escola Politécnica da UFRJ
2026-10-20

> **Este texto é a terceira versão do relatório sobre o projeto ww3-gpu.**
>
> - **Vale o original.** Se este texto e os arquivos do repositório discordam, valem os arquivos. Os arquivos principais são `kokkos/PORT_STATUS.md`, `kokkos/ports.tsv` e o `README.pt-BR.md`.
> - **Feita a partir de:** o repositório em 2026-10-20, commit `b8a6463` de `main`. A versão anterior usou o commit `23130fe`, de 2026-10-16.
> - **Para quem é:** o Prof. Pedro Cruz, do GTA (Grupo de Teleinformática e Automação, DEL/UFRJ), e qualquer pessoa que programa, mas não estuda oceanografia nem física.
> - **O que ficou de fora:** as equações, os detalhes de cada rotina e as tabelas completas. Cada trecho resumido aponta para o arquivo de origem.
> - **Como foi escrita:** o texto foi gerado por Claude com a skill Português Técnico Controlado (PTC), versão 1.1.0, de Kayque Rotondo. A revisão é de Matheus Hoffmann. A última seção diz como a skill foi aplicada.

Os links, num lugar só

O quê	Onde
Código (GitHub)	https://github.com/h0ffmann/ww3-gpu
Resumo do projeto em português	`README.pt-BR.md`
Site	https://h0ffmann.github.io/ww3-gpu/ (em português: https://h0ffmann.github.io/ww3-gpu/pt-BR/)
Esta página no site	https://h0ffmann.github.io/ww3-gpu/relatorio-gta/
Zenodo (o DOI que abre sempre a versão mais recente)	10.5281/zenodo.23221351
Métricas do port	`kokkos/PORT_STATUS.md`, `kokkos/PORT_TABLE.tsv`, `kokkos/PORT_RANKING.md` e a seção "port" do site
Resultados na CPU, escritos para os modeladores da NOAA	`docs/NOAA_PROGRESS_RECORD_202610.md`

O quê	Onde
O que falta para uso operacional	`docs/PRODUCTION_READINESS_202610.md`
Decisões (ADRs, *Architecture Decision Records*)	`docs/ADRs/` e a página https://h0ffmann.github.io/ww3-gpu/adrs/
Desenhos de mudança (WFIPs, *Wave Forecaster Improvement Proposals*)	`docs/WFIPs/`
Planos de engenharia	`docs/compound/plans/`
Diário do que foi tentado	`docs/log/`
O livro (17 lições)	https://h0ffmann.github.io/ww3-gpu/book/ e o PDF
O pedido de acesso à H100	h0ffmann/ww3-gpu#143
O DIA (*Discrete Interaction Approximation*) na GPU, versão 2	h0ffmann/ww3-dia-gpu-v2, comparado com o original ww3-dia-gpu
O artigo com receita parecida	Koldunov et al., 2026, arXiv:2606.11356
Glossário de siglas	`docs/GLOSSARY.md`

Como ler as marcas

Cada afirmação do repositório tem uma marca. **(v)** quer dizer "verificado". Nesse caso, uma pessoa ou um agente conferiu a afirmação numa fonte ou num comando, e o texto nomeia essa fonte. ⚠ quer dizer "ainda não verificado". Todo número vem com o comando que reproduz o número. Este relatório segue a mesma regra.

---

1. O problema, em linguagem de computação

O modelo. O WAVEWATCH III® (WW3) é o modelo de previsão de ondas da NOAA, a agência americana de oceano e atmosfera. O WW3 é um programa em Fortran com 263.375 linhas (v, `kokkos/PORT_STATUS.md`, contadas no commit `03adda91` do WW3).

O que o WW3 calcula. O modelo divide o mar numa grade de pontos. Em cada ponto de mar, o WW3 guarda um vetor de números chamado espectro. O espectro diz quanta energia de onda existe em cada frequência e em cada direção. A cada passo de tempo, o programa faz duas etapas:

1. **Propagação:** o programa move a energia de um ponto da grade para os pontos vizinhos. A etapa lembra um *stencil* sobre uma imagem.
2. **Termos-fonte:** em cada ponto, o programa soma a energia que o vento coloca, a energia que a quebra das ondas tira e a energia que as ondas trocam entre si. Nesta etapa, um ponto não depende de outro ponto.

Por que a GPU ajuda. A segunda etapa é um laço sobre pontos independentes: 9.520 pontos de mar no caso `full`. Esse laço tem o formato de um *map* sobre um vetor grande, e uma GPU executa esse formato bem. No perfil medido, só o DIA ocupa 48,4 % do tempo de execução (seção 4).

A regra que torna o problema difícil. A versão em GPU precisa dar **o mesmo resultado, bit a bit**, que o Fortran original, dentro do mesmo executável do WW3. Um resultado parecido não basta. Se um bit muda, a tradução está errada até que duas execuções do próprio Fortran mostrem a mesma diferença (`AGENTS.md`, "Bit for bit with the Fortran").

---

2. A fase atual do projeto

Velocidade primeiro, validação depois. Em 2026-10-17, o dono do projeto fixou o objetivo principal: deixar o WW3 mais rápido com Kokkos e CUDA, sem mudar a aritmética do Fortran (ADR-0016). A mesma decisão adiou os regtests do WW3 para uma **fase de validação**. O dono do projeto decide quando essa fase começa. Até o início dessa fase, o projeto mostra a paridade bit a bit por análise estática do código compilado (seção 7). Todo número de velocidade dessa fase leva a marca "regtest pendente ⚠".

O que mudou de 2026-10-16 a 2026-10-19. O `main` recebeu 269 commits nesse intervalo, em 39 pull requests, do #158 ao #206 (v, `git log 3445100..b8a6463`). Os seis grupos de mudança abaixo resumem esses commits:

1. **Tradução em massa.** Os PRs de #159 a #168 traduziram as rotinas mais caras que ainda estavam em Fortran e ligaram essas rotinas ao fork. No intervalo inteiro, o número de rotinas traduzidas foi de 91 para 316, e o número de rotinas ligadas foi de 10 para 72.
2. **O passo de tempo residente.** Com `--kokkos resident`, o espectro fica no lado do Kokkos durante a execução inteira. Sete partes do passo de tempo executam em Kokkos (seção 3, WFIP-0005; PRs #173, #179, #184 e #191).
3. **A matemática da GPU.** Uma GPU NVIDIA calcula `expf` e `logf` com algoritmos diferentes dos algoritmos da `glibc`. Os PRs #177 e #178 trocaram essas chamadas por cópias das funções da `glibc` compiladas para a GPU (WFIP-0006). Nenhuma execução na GPU comparou ainda essas cópias.
4. **Produção num nó só.** O PR #191 atualizou o pin do fork e acrescentou o modo estrito. O modo estrito interrompe a execução quando uma parte volta para o Fortran sem aviso. O mesmo PR mostrou que o `ww3_multi` e os builds com OpenMP também dão saídas idênticas byte a byte às do Fortran (ADR-0017).
5. **Pontos em vetor e grade não estruturada.** Desde os PRs #199 e #201, o código Kokkos calcula oito pontos de mar ao mesmo tempo, um ponto por posição do registrador SIMD (*Single Instruction, Multiple Data*) da CPU. Os PRs #202 e #204 traduziram a propagação na grade não estruturada (`W3XYPUG`), e o regtest `ww3_tp2.6` deu os bytes do Fortran.
6. **O caminho para o GFS-Wave.** O PR #206 levou o `W3SRCE` em lote para a switch dos regtests do GFS-Wave (Global Forecast System, ondas), o sistema que a NOAA usa na previsão operacional de ondas (plano 007).

3. Como o código é organizado: as formas de executar

O código do WW3 não é editado neste repositório. O código vem de fora, em submódulos do git, isto é, repositórios dentro do repositório. O ww3-gpu acrescenta só a reescrita em C++ e as ferramentas em volta (v, `README.pt-BR.md`, "como funciona").

Os forks

Diretório	O que é	Para que serve
`WW3-noaa/`	o WW3 da NOAA, NOAA-EMC/WW3 no commit `03adda91`, sem mudança	a referência: o resultado que o projeto precisa reproduzir
`WW3/`	o fork h0ffmann/WW3 no commit `96892c95` (branch `ww3-gpu/gfs-srce-be5bdbea`): o WW3 da NOAA mais o patch KOKKOS. O patch muda 9 arquivos e acrescenta 7 módulos em `model/src/`, com 5.902 linhas acrescentadas e nenhuma linha removida	colocar dentro do WW3 a chamada para o código novo
`WW4/`	o fork h0ffmann/WW4, branch `develop`: o WAVEWATCH IV, que a NOAA reescreve em C++	acompanhar o sucessor do WW3
`picasso/`	h0ffmann/picasso (10.5281/zenodo.23311208): o conjunto de compiladores fixado com Nix	dar a todas as pessoas as mesmas versões de compilador

v. Os números do patch vêm de `git -C WW3 diff --shortstat 03adda91 96892c95 -- model` e de `git -C WW3 diff --name-status`, executados em 2026-10-20.

Por que o fork do WW3 existe. A chamada para o código em C++ precisa estar dentro do WW3. Este repositório não edita o WW3, então o fork guarda essa chamada. A chamada fica atrás da chave de compilação `KOKKOS`. Antes de cada execução, o script `scripts/ww3-gpu.sh` compara o fork com o WW3 da NOAA. Se o fork muda um arquivo fora do patch, o script termina com o código de saída 3.

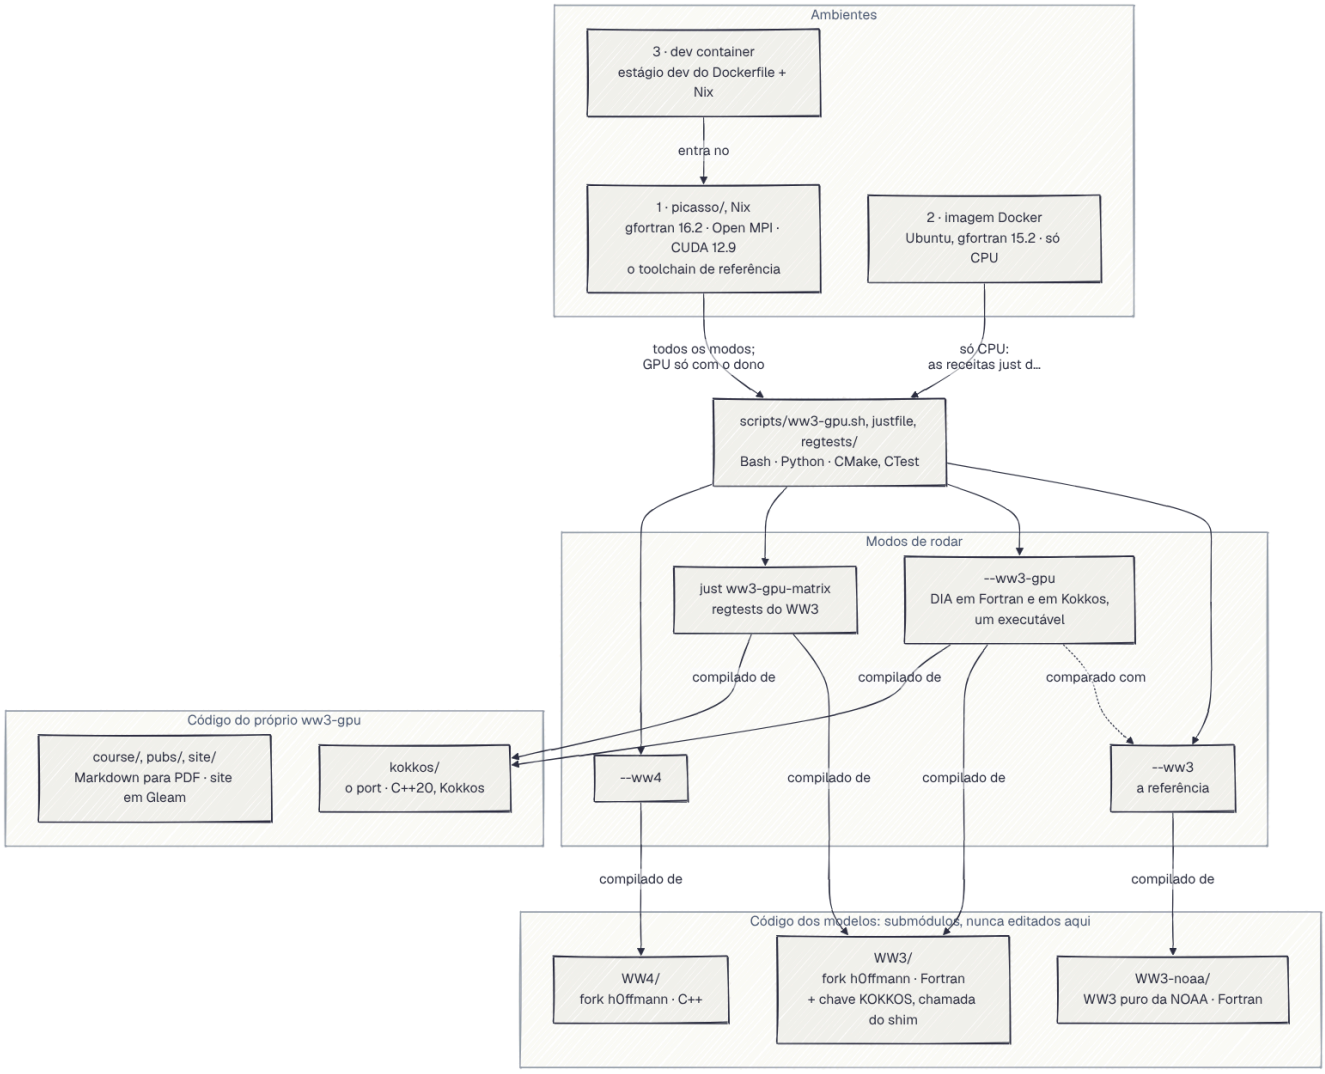
Os três modos de executar

O script `scripts/ww3-gpu.sh` controla os três modos:

Modo	O que executa	Compilado de
`--ww3`	o WW3 como a NOAA escreve	`WW3-noaa/`

Modo	O que executa	Compilado de
`--ww3-gpu`	o WW3 do fork com o código Kokkos. O script executa o caso duas vezes no mesmo executável, uma vez com o Fortran e uma vez com o Kokkos, e compara as saídas	`WW3/` e `kokkos/`
`--ww4`	o WAVEWATCH IV. Hoje esse modo termina com o código de saída 5, porque o WW4 ainda não tem as partes que os casos usam	`WW4/`

Cada modo aceita `--cpu` (o padrão) ou `--gpu`. Só o `--ww3-gpu` tem caminho de GPU. Uma execução na GPU exige uma pessoa como supervisora. O script pede um "yes" digitado no terminal e não continua sem essa resposta.

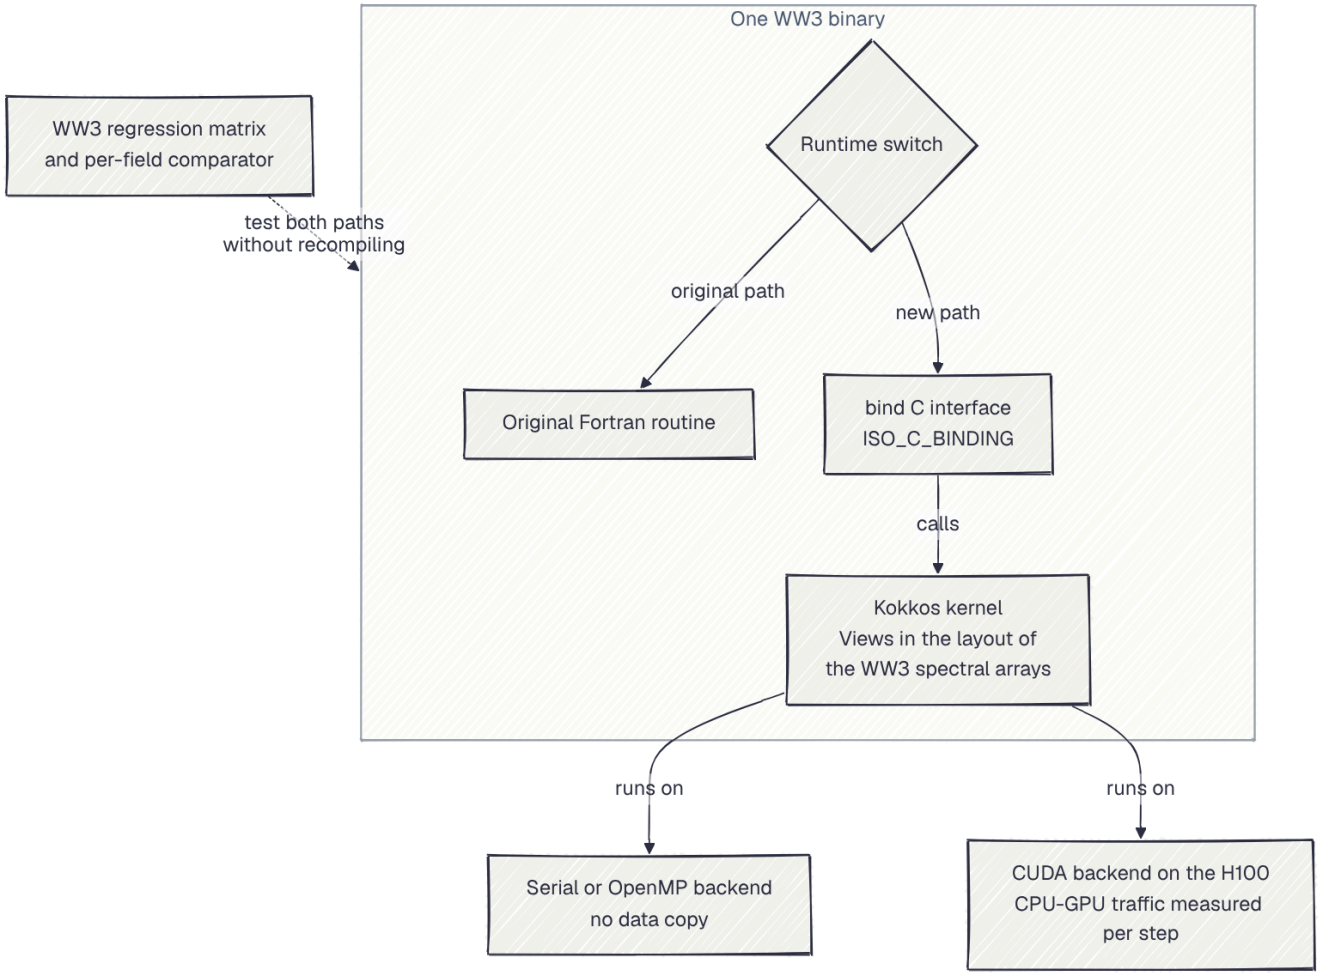


O sistema inteiro numa página: de onde vem o código, o que o ww3-gpu acrescenta, os modos de executar e os ambientes.

A chave em tempo de execução

O executável do `--ww3-gpu` contém as duas versões de cada rotina ligada. Uma variável de ambiente escolhe a versão, sem recompilar: `WW_KOKKOS_<PARTE>=0` usa o Fortran e `WW_KOKKOS_<PARTE>=1` usa o Kokkos. Assim, o teste compara as duas versões com o mesmo binário, a mesma entrada e o mesmo compilador. A opção `--kokkos` escolhe um conjunto de partes:

`--kokkos`	Partes em Kokkos	Uso
`none`	nenhuma parte	só o Fortran, no build com Kokkos
`all`	todas as partes do build	o teste mais amplo da tradução
`gpu`	`SRCE`	o padrão do `--gpu`: o `W3SRCE` inteiro em cada chamada (ADR-0013)
`resident`	`SRCE`, `XYP3`, `KTP3`, `OUTG`, `IOPE`, `UPDV`, `CPRT`	o passo de tempo inteiro em Kokkos, com o espectro guardado no lado do Kokkos



Um executável do WW3, dois caminhos: a chave escolhe a rotina original em Fortran ou o kernel em Kokkos, que executa em CPU ou em GPU.

Kokkos é uma biblioteca C++ do Sandia National Laboratories (⚠, `docs/GLOSSARY.md`). Quem programa escreve o kernel uma vez e compila esse kernel para vários *backends*: Serial, OpenMP (vários núcleos da CPU) ou

CUDA (GPU NVIDIA). O Fortran chama o C++ por uma interface `bind(C)`, o padrão `ISO_C_BINDING` do Fortran.

Por que o espectro fica no lado do Kokkos. A GPU tem memória própria. Se cada rotina copia o espectro para a GPU e de volta, as cópias ocupam a maior parte do tempo da chamada. No benchmark do DIA, a chamada inteira levou 0,75 ms, e o kernel levou 0,047 ms: as cópias foram cerca de 94 % da chamada (v, `bench/results/`). O preset `resident` copia o espectro para o lado do Kokkos uma vez, no começo. O espectro volta ao Fortran só quando o WW3 escreve uma saída ou um restart, e no fim da execução.

Os três ambientes

O mesmo script funciona em três ambientes (v, `README.pt-BR.md`, "três ambientes"):

1. **picasso (Nix):** a referência. Os veredictos bit a bit e todo tempo medido vêm desse ambiente.
2. **Imagem Docker:** só CPU e só os casos pequenos, para quem não quer instalar o Nix. Uma pessoa inicia à mão um workflow do GitHub Actions. Esse workflow publica as imagens no GHCR (GitHub Container Registry).
3. **Dev container:** para o VS Code. Por dentro, o dev container usa o picasso.

---

4. O que já foi portado

O que "portado" quer dizer neste relatório. Uma rotina está **portada** quando o WW3 chama o código Kokkos e esse código passa nos testes de regressão originais da NOAA (os *regtests*) com o resultado do Fortran. Traduzir não basta. Compilar não basta. O ww3-gpu não muda a lógica dos regtests. Os regtests são a tabela verdade da verificação (seção 7).

O site e o `PORT_STATUS.md` contam o trabalho em três níveis. Cada nível exige mais do que o nível anterior:

Nível	O que quer dizer	Parte do tempo de execução	Rotinas	Linhas do WW3
traduzido	o código Kokkos existe e foi conferido só por leitura	**99,3 %**	316 de 1.023	69.024 de 263.375 (26,21 %)
ligado	o WW3 do fork chama esse código, atrás da chave	**99,3 %**	72 de 1.023	19.059 (7,24 %)
portado	os regtests executaram com o código dentro do WW3 e deram o resultado do Fortran	**48,6 %**	14 de 1.023	3.151 (1,20 %)

v. `python3 scripts/port_score.py --check`, executado em 2026-10-20 no commit `b8a6463`: as tabelas estão em dia. O código Kokkos tem 62.257 linhas de C++ em 355 arquivos. Na versão anterior deste relatório, os números eram 91, 10 e 2 rotinas, com 19.491 linhas de C++. Nos arquivos do repositório, em inglês, os três níveis se chamam *translated*, *ported* e *regtested*. Neste relatório, "portado" é o terceiro nível.

A distância entre os níveis. A distância entre 99,3 % e 48,6 % é o trabalho que falta. Esse trabalho é a fase de validação: passar cada unidade ligada nos regtests da NOAA.

As 14 rotinas portadas (v, coluna `regtested` de `kokkos/ports.tsv`):

- **O DIA:** `W3SNL1` e as tabelas do DIA, `INSNL1`. O DIA é 48,4 % do tempo no perfil. O resultado é idêntico byte a byte ao Fortran nas 125 entradas da matriz de regtests do WW3 (100 seriais e 25 com OpenMP; 2026-10-15, `port_report/W3SNL1_KOKKOS.md`).
- **O suporte do `W3WAVE`:** `W3GATH`, `W3SCAT`, `W3UWND`, `W3DZXY`, `WAVNU2`, `DISTAB`, `W3MAP3` e `W3MAPT`. A verificação usou os casos `smoke` e `full` (2026-10-16).
- **A grade não estruturada:** `W3XYPUG` e `W3XYPFSN2`. As duas entradas do regtest `ww3_tp2.6` deram os bytes do Fortran (2026-10-19, `docs/log/2026-10-19-xypug-tp2.6-rebased.md`).
- **O `ww3_multi`:** `WMIOHG` e `WMIOEG`, nas entradas de `mww3_test_01` a `mww3_test_05`.

Uma ressalva sobre a contagem. O caso `smoke` é o regtest `ww3_ts1` da NOAA. O caso `full` (`bench_small`, 9.520 pontos de mar) é um caso do próprio repositório, e a contagem do repositório inclui esse caso. Oito das 14 rotinas passaram só pelos casos `smoke` e `full`, com comparação byte a byte dentro do WW3. Essas oito rotinas contam como portadas porque a contagem inclui o caso `full`. Essas oito rotinas ainda não passaram pela matriz completa da NOAA.

As rotinas só ligadas. A física ST4 (o conjunto de termos-fonte que a chave de compilação `ST4` escolhe) tem três rotinas ligadas ao WW3: `W3SIN4` (o vento), `W3SDS4` (a quebra das ondas) e `W3SPR4` (os parâmetros médios). O `W3SRCE` e a propagação (`W3XYP3`, `W3KTP3`, `W3QCK1`, `W3QCK3`) também estão ligados ao WW3. Essas rotinas deram saídas idênticas byte a byte nos casos de teste. A matriz de regtests dessas rotinas espera a fase de validação.

---

5. Velocidade: o que foi medido

Todos os números desta seção foram medidos numa CPU Intel Core i9-14900 (24 núcleos, 32 threads) e numa GPU RTX 4090. Os números de modelo inteiro estão marcados com "regtest pendente ⚠".

Medição	Resultado	Fonte
Modelo inteiro na CPU, caso `full`, 32 threads, preset `resident`	15,84 s contra 26,18 s do WW3 da NOAA: **1,65 vez mais rápido** (39,5 % menos tempo); regtest pendente ⚠	mediana de dez execuções, 2026-10-18, registro da NOAA, seção 3
O mesmo caso com 1 thread	174,78 s contra 174,27 s: o mesmo tempo	uma execução, máquina compartilhada ⚠

Medição	Resultado	Fonte
Kernel do DIA, fora do WW3, 1.000 pontos por chamada, 1 thread	25,88 ms	mediana de três, 2026-09-15, `bench/results/`
O mesmo kernel com OpenMP, 32 threads	5,95 ms (4,4 vezes)	a mesma fonte
O mesmo kernel com CUDA, RTX 4090, com as cópias	0,75 ms (34 vezes)	a mesma fonte
O mesmo kernel com CUDA, só o kernel	0,047 ms	a mesma fonte
Modelo inteiro na GPU	nenhuma execução até 2026-10-20; o build CUDA compila	`docs/log/2026-10-18-cuda-build-only.md`

Como ler esses números. O ganho de 1,65 vez na CPU vem da divisão do trabalho entre threads. Com 1 thread, o Kokkos e o Fortran levam o mesmo tempo. O ganho só existe nos builds de memória compartilhada (`SHRD`). No build com MPI (*Message Passing Interface*), que o GFS-Wave usa, o WW3 executa o Fortran por decisão de projeto (ADR-0017). O 34 vezes do DIA vale só para o kernel isolado, não para o WW3 inteiro.

---

6. A receita: tradução com disciplina

O artigo parecido. A receita do livro lembra a receita de Koldunov et al. (2026), "An Ocean Model Ported by a Large Language Model: Experience and Lessons from FESOM2 (Fortran to C to C++/Kokkos)" (arXiv:2606.11356). Nesse trabalho, especialistas dirigiram um assistente de código. O assistente traduziu cerca de 74 mil linhas de Fortran do modelo oceânico FESOM2 para C e depois de C para C++ com Kokkos. O assistente traduzia linha a linha, sem mudar o algoritmo para ganhar velocidade. Cada etapa tinha um teste de aceitação próprio (v, resumo do arXiv, lido em 2026-10-16).

Onde o ww3-gpu é diferente. A estratégia do ww3-gpu é a **tradução com disciplina, direta de Fortran para Kokkos**:

- **Sem etapa em C.** Cada instrução do Fortran vira uma instrução em C++, na mesma ordem. A ordem dos laços muda só onde um kernel não pode alocar memória. O tipo `float` substitui o `REAL` do WW3, e a álgebra não muda.
- **Sem testes próprios do Kokkos.** O código Kokkos não tem teste unitário, GoogleTest nem dado capturado de uma rotina traduzida (ADR-0010). A ADR-0019, ainda proposta, propõe permitir GoogleTest só para a infraestrutura que não traduz rotina do WW3.
- **Sem regtests durante a tradução.** Durante a tradução, o projeto mostra a paridade pela comparação do código que os dois compiladores produzem com `-O3` (GIMPLE ou desmontagem) (ADR-0016, que substitui a ADR-0011).
- **O teste vem depois, de uma vez, dentro do WW3.** Na fase de validação, cada unidade ligada ao fork passa pelos regtests da NOAA. O DIA (`W3SNL1`) seguiu esse caminho com sucesso: o resultado foi idêntico

byte a byte nas 125 entradas que executaram (100 seriais e 25 com OpenMP).

O ciclo de trabalho. O projeto tem uma pessoa só. Cada mudança de engenharia segue o ciclo do plugin Compound Engineering, no tamanho da mudança: planejar, fazer, revisar e registrar o que a mudança ensinou. Uma mudança pequena vai direto ao trabalho e às verificações. Os planos ficam em `docs/compound/plans/`.

---

7. Como a tradução é verificada

O regtest é a tabela verdade. Os únicos testes do código Kokkos são os testes do próprio WW3: os regtests que a NOAA mantém na matriz `regtests/bin/matrix.base`. O ww3-gpu não muda a lógica desses testes. Cada entrada executa duas vezes no mesmo executável, uma vez com o Fortran e uma vez com o Kokkos. O `test.comp` da NOAA compara as saídas. Um arquivo diferente reprova a rotina (ADR-0010).

A ferramenta de tolerância: `nccmp-tol`. O `nccmp-tol` trabalha ao lado do `test.comp`. O `nccmp-tol` compara dois arquivos NetCDF (*Network Common Data Form*, um formato de arquivo científico) variável por variável. Cada variável tem uma tolerância absoluta e uma tolerância relativa no arquivo `tolerances.txt`. Por exemplo, a altura de onda `hs` aceita uma diferença absoluta de até 0,0001 m ou uma diferença relativa de até 0,0001. O `nccmp-tol` mede o tamanho de cada diferença, campo por campo.

O `nccmp-tol` nunca transforma uma diferença em aprovação: o veredicto é do `test.comp`, bit a bit. Uma pessoa revisa toda mudança num script de comparação ou numa tolerância antes do merge (`AGENTS.md`, "Never cheat a regtest tool").

A exceção. O projeto perdoa só um arquivo que o próprio Fortran escreve de forma diferente em duas execuções seguidas. A matriz mede esse caso com uma segunda execução do Fortran.

Duas proteções novas. O modo estrito (`WW_KOKKOS_STRICT=1`) interrompe a execução quando uma parte volta para o Fortran. Com `WW_KOKKOS_VA_POISON=1`, o código Kokkos preenche com NaN a cópia desatualizada do espectro no lado do Fortran. Se uma rotina do Fortran lê essa cópia sem sincronizar, uma saída muda, e a comparação byte a byte falha.

Por que bit a bit é difícil. O repositório registra dois exemplos reais. Primeiro: com a contração ligada, o compilador junta `a*b + c` numa instrução só (FMA). A FMA arredonda uma vez, e às vezes o resultado muda no último bit. Por isso o projeto compila o código Kokkos com `-ffp-contract=off` e, na GPU, com `--fmad=false`. Segundo: o gfortran expande `x**11` de um jeito em `-O0` e de outro jeito em `-O3` (v, `docs/log/2026-10-14-snl1-bitwise-af11.md`).

---

8. O DIA na GPU: ww3-dia-gpu e ww3-dia-gpu-v2

Em março de 2026, outro autor propôs à NOAA um kernel CUDA do DIA, o ww3-dia-gpu original (commit `38919d2`, de 2026-03-26). O ww3-dia-gpu-v2, criado em 2026-10-15, documenta a versão deste projeto e

compara as duas versões (v, `docs/W3SNL1_GPU_COMPARISON_202610.md`).

	ww3-dia-gpu (original)	ww3-dia-gpu-v2 (este projeto)
O que calcula	uma parte da seção 3 do `W3SNL1` (`SA1`, `SA2`), com dados sintéticos	o `W3SNL1` inteiro e as tabelas do DIA (`INSNL1`): a fonte `S` e a diagonal `D`
Chamado pelo WW3	não	sim, pelo `W3SRCE` do fork, atrás da chave `KOKKOS`
Bit a bit contra	o próprio kernel, em outra ordem de laço	o Fortran, dentro do mesmo executável do WW3
Regtests da NOAA	nenhuma entrada possível	125 de 125 entradas idênticas byte a byte (100 seriais e 25 com OpenMP)
Velocidade publicada	16,8 vezes, layout contra layout, na mesma RTX 3060	34 vezes contra 1 núcleo, numa RTX 4090, com as cópias de memória

Os dois números de velocidade não são comparáveis. As GPUs são diferentes, a quantidade de trabalho é diferente, e nenhum dos dois números mede o WW3 inteiro.

---

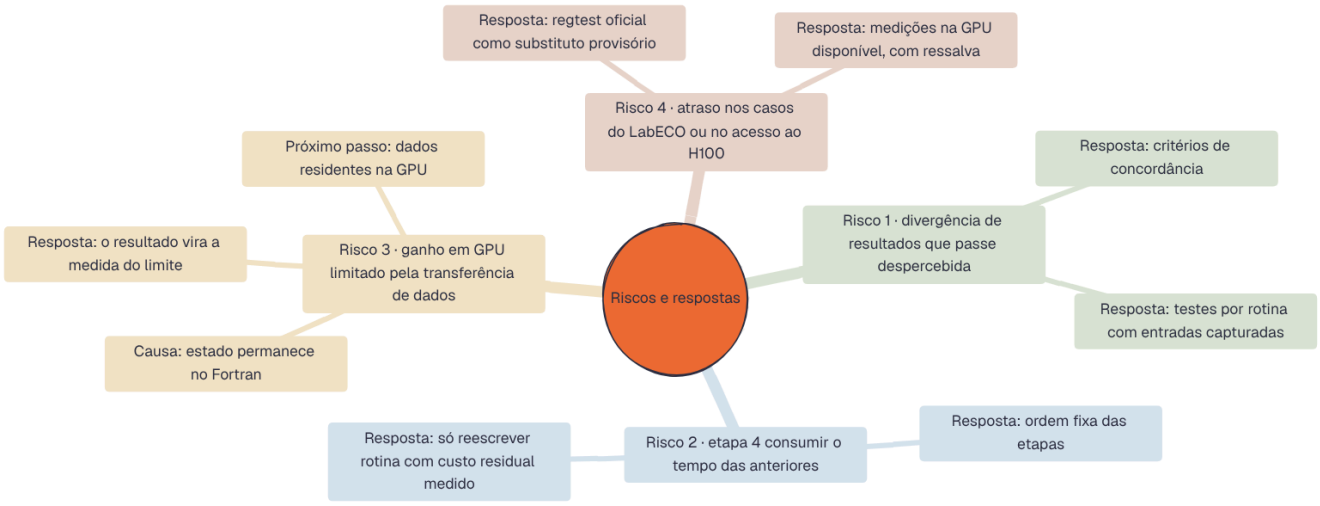
9. A H100 e a primeira execução na GPU

A pergunta do projeto é: o WW3 fica mais rápido na GPU **sem mudar a resposta**? Responder a essa pergunta exige três medidas na mesma máquina:

- **A tradução** diz que o código existe e compila para a GPU. Hoje a tradução cobre 99,3 % do tempo.
- **O regtest** diz que o código dá os mesmos bits que o Fortran. Hoje 48,6 % do tempo está portado, e só na CPU.
- **O tempo** vale só quando o regtest passou na mesma máquina.

A primeira execução na GPU. O build CUDA do preset `resident` compila. O nvcc emite 51 avisos no código Kokkos, e nenhum aviso está numa parte ligada (v, `docs/log/2026-10-18-cuda-build-only.md`). O plano 003 descreve a primeira execução supervisionada, numa RTX 4090. O dono do projeto vai iniciar essa execução no terminal. Até 2026-10-20, essa execução não aconteceu. Na GPU, a regra é diferente da regra da CPU: o `nccmp-tol` julga a execução pelas tolerâncias, e o registro da execução guarda a diferença de cada campo, sem alargar tolerância (ADR-0014).

A H100. A issue h0ffmann/ww3-gpu#143, aberta em 2026-10-16, pede acesso à NVIDIA H100 do LabECO, na UFSC. A issue lista o que conferir: o driver, o CUDA para `sm_90`, o Nix, os contêineres, o escalonador e o uso exclusivo da GPU para medir. Até 2026-10-20, a issue está aberta. O repositório já tem um preset `cuda-h100-release`. Na H100, o projeto precisa de duas medições: os regtests do WW3, Fortran contra Kokkos, para a paridade, e a mediana de três execuções, para o tempo. Sem esse acesso, os números da H100 na proposta continuam projeções (⚠).



Os riscos do projeto e a resposta a cada risco, segundo a proposta. O "Risco 4" é o acesso à H100.

---

10. ADRs e WFIPs: como as decisões ficam escritas

Agentes de código (Claude Code) fazem parte do trabalho deste projeto. Para conferir o trabalho de um agente, o projeto escreve toda decisão e todo plano no repositório, com data e evidência.

ADR (*Architecture Decision Record*, registro de decisão) é um texto curto sobre uma escolha já feita. A ADR descreve o contexto, a decisão, as alternativas e as consequências. Uma ADR não agenda trabalho. Uma ADR aceita não muda. Uma ADR nova substitui a ADR antiga.

O repositório tem 18 ADRs (`docs/ADRs/`). Estas ADRs importam mais para o port:

ADR	Decisão	Situação
ADR-0002	portar na ordem do tempo medido, a rotina mais cara primeiro	aceita
ADR-0010	o código Kokkos não tem testes próprios; os regtests do WW3 são os únicos testes	aceita
ADR-0014	a GPU é julgada pelas tolerâncias do `nccmp-tol`; a CPU continua bit a bit	aceita
ADR-0016	velocidade é o objetivo; os regtests vão para a fase de validação	aceita; substitui a ADR-0011
ADR-0017	o código Kokkos executa num nó só; o build com MPI fica no Fortran	aceita
ADR-0019	GoogleTest só para a infraestrutura, nunca para uma rotina traduzida	proposta

WFIP (*Wave Forecaster Improvement Proposal*) é o desenho de uma mudança grande, escrito **antes** da mudança. Cada WFIP aponta para um entregável da proposta do projeto (de D1 a D6). Cada WFIP tem uma lista de "pronto" (*definition of done*) que conta quanto falta. Um script reprova a integração contínua (CI) quando o índice fica desatualizado. O formato lembra um RFC (*Request for Comments*) ou um *design doc*. O repositório tem cinco WFIPs (`docs/WFIPs/`):

WFIP	O que desenha	Situação
WFIP-0001	executar o WW3 com vento do WeatherNext 3 numa RTX 4090	adiada (2026-10-15)
WFIP-0002	o laboratório como livro, compilado do repositório	parcial: 1 de 7 itens
WFIP-0003	o DIA em Kokkos pela matriz de regtests do WW3, no fork	**implementada** em 2026-10-15: 7 de 7 itens
WFIP-0005	o passo de tempo residente: o espectro mora na GPU	rascunho: 0 de 8 itens
WFIP-0006	a GPU calcula os bits da `libm` da `glibc`	parcial: unidades de 1 a 4, num total de 5

---

11. O próximo passo

A ordem do trabalho segue o tempo medido (`kokkos/PORT_RANKING.md`). Todas as rotinas de cálculo que o perfil mede já estão traduzidas. O que resta no ranking são as rotinas de inicialização e as rotinas de entrada e saída. As três frentes abertas em 2026-10-20 são:

1. **O GFS-Wave.** O plano 007 leva o `W3SRCE` em lote e o `W3XYP3` para a switch dos regtests do GFS-Wave (de `ww3_ufs1.1` a `ww3_ufs1.3`). O passo 1 está pronto. Os passos de 2 a 4 estão bloqueados (`docs/log/2026-10-19-gfs-risk-runs.md`).
2. **A primeira execução na GPU**, supervisionada pelo dono do projeto (plano 003).
3. **As lacunas para uso operacional.** O `PRODUCTION_READINESS_202610.md` lista 13 lacunas em ordem de gravidade. Três lacunas bloqueiam o uso no GFS-Wave:
   - nenhuma switch de regtest tem o conjunto de termos-fonte que o `W3SRCE` em Kokkos traduz;
   - o MPI fica fora do código Kokkos;
   - a paridade não foi medida com o compilador da operação nem na GPU.

Depois dessas frentes, o dono do projeto vai iniciar a fase de validação.

12. Como citar

Cite o DOI que abre sempre a versão mais recente: 10.5281/zenodo.23221351. O registro no Zenodo é do tipo livro. A versão publicada mais recente é a `v0.1.3`, de 2026-10-09 (v, `RELEASES.md`). Os dados para citação estão em `CITATION.cff` e no `README.md`.

Glossário do projeto

A PTC-6 da skill pede um termo para cada conceito, sempre o mesmo termo. Esta tabela fixa os termos deste relatório.

Termo	Definição em uma linha	Não usar
backend	o alvo para o qual o Kokkos compila o kernel: Serial, OpenMP ou CUDA	plataforma
bit a bit	os dois resultados têm exatamente os mesmos bits, sem tolerância	igual, parecido
DIA	o método aproximado que o WW3 usa para as trocas de energia entre ondas	—
execução	um processamento completo de um caso, do começo ao fim	rodada
FMA	uma instrução que calcula `a*b + c` com um arredondamento só	—
GIMPLE	a representação intermediária do GCC (*GNU Compiler Collection*), a mesma para Fortran e C++	—
ligado	o WW3 do fork chama o código Kokkos, atrás da chave	portado
`nccmp-tol`	o comparador de NetCDF com tolerância por variável; mede a diferença, não aprova	validador
portado	o código Kokkos passou nos regtests da NOAA dentro do WW3	traduzido, ligado
regtest	um caso de teste completo do WW3, com entrada e saída de referência; a tabela verdade	teste unitário

Termo	Definição em uma linha	Não usar
shim	a camada fina que liga o Fortran ao C++	adaptador
termo-fonte	a parte do cálculo feita ponto a ponto, sem olhar os vizinhos	—
traduzido	o código Kokkos existe e foi conferido só por leitura	portado

---

Referências

- `README.pt-BR.md` do ww3-gpu, commit `b8a6463`, lido em 2026-10-20. O resumo do projeto em português. As seções "em um minuto", "como funciona", "onde o projeto está" e "três ambientes" deram o contexto deste relatório. Os números do README são de 2026-10-17. Este relatório usa os números de 2026-10-20 do `PORT_STATUS.md`.
- `kokkos/PORT_STATUS.md` e `kokkos/ports.tsv`, commit `b8a6463`.
- `docs/NOAA_PROGRESS_RECORD_202610.md`, versão de 2026-10-18.
- `docs/PRODUCTION_READINESS_202610.md`.
- Koldunov et al., 2026, arXiv:2606.11356.
- Rotondo, K. Português Técnico Controlado, versão 1.1.0, commit `cfdffad`, licença MIT.

Como este texto foi escrito

Claude gerou este texto com a skill Português Técnico Controlado (PTC), versão 1.1.0, de Kayque Rotondo, a pedido de Matheus Hoffmann. A skill reescreve texto técnico em português para que cada frase tenha uma leitura só.

Parâmetros do Passo 0 da skill: nível `descritivo` (documentação de sistema), destinatário humano, texto só em português. O pedido não fixou o nível. O nível `descritivo` foi inferido do leitor: um professor que lê o relatório, não um operador que segue um procedimento.

O que mudou em relação à segunda versão, regra por regra:

Regra	Antes	Depois
PTC-1 (sujeito explícito)	"Medimos onde o tempo vai"	"O perfil medido mostra que os termos-fonte ocupam a maior parte do tempo"
PTC-5 (adjetivo antes do nome)	"Se um único bit muda"	"Se um bit muda"

Regra	Antes	Depois
PTC-1 (verbo "parar" lido como preposição)	"o script para com o código de saída 3"	"o script termina com o código de saída 3"
PTC-3 (tempo verbal)	"O dono do projeto inicia essa fase"	"O dono do projeto decide quando essa fase começa"
PTC-6 (termo congelado)	"rodada", "rodar"	"execução", "executar"
PTC-7 (data)	"16 de outubro de 2026"	"2026-10-16"
PTC-7 (milhar)	"9 520", "1 000"	"9.520", "1.000"

Mantido de propósito. Os nomes de rotina, de arquivo, de variável e de comando ficaram como no código (`W3SNL1`, `--kokkos resident`). As marcas `(v)` e ⚠ do repositório ficaram. As citações de títulos em inglês ficaram em inglês. As ressalvas sobre máquina compartilhada e regtest pendente ficaram longas, porque cortar essas ressalvas mudaria o fato.